

# คู่มือ SOAP Note ด้วย AI ที่รันในเครื่อง

เวชระเบียนจากเสียงสนทนา สำหรับคลินิกและโรงพยาบาลไทย

นพ. สหรัถ อังศุมาศ · ประสาทแพทย์ ฉบับที่ 1 · สิงหาคม 2569

## สารบัญ

- เอกสารนี้คืออะไร
- ⚠️ ขอบเขตและข้อจำกัด — อ่านก่อนใช้**
- ระบบทำงานอย่างไร
- สเปกเครื่องที่ต้องใช้
- ขั้นตอนการใช้งานประจำวัน
- เคล็ดลับการพูดให้ได้ note ที่ดี
- การบันทึกผลตรวจร่างกาย
- ความเป็นส่วนตัวและ PDPA
- ตัวเลขจากการใช้งานจริง
- บทเรียนสำหรับผู้ที่จะสร้างเอง
- ปัญหาที่พบบ่อยและวิธีแก้

## 1. เอกสารนี้คืออะไร

ระบบนี้แปลง บทสนทนาระหว่างแพทย์กับผู้ป่วย ให้เป็น ร่างเวชระเบียนรูปแบบ SOAP note ภาษาไทย โดยประมวลผลทั้งหมดในเครื่องคอมพิวเตอร์ของผู้ใช้เอง ไม่ส่งข้อมูลออกสู่อินเทอร์เน็ต

พัฒนาโดยประสาทแพทย์คนเดียว ใช้งานจริงในคลินิกส่วนตัว จุดเริ่มต้นมาจากปัญหาที่แพทย์ทุกคนเจอ คือเวลาที่หมดไปกับการพิมพ์เวชระเบียนหลังตรวจเสร็จ ซึ่งเป็นเวลาที่ควรได้ใช้กับผู้ป่วยหรือได้พักผ่อน

สิ่งที่ทำให้ระบบนี้ต่างจากบริการเชิงพาณิชย์

|                    | บริการ scribe ต่างประเทศ | ระบบนี้                          |
|--------------------|--------------------------|----------------------------------|
| ข้อมูลผู้ป่วย      | ส่งขึ้นคลาวด์ต่างประเทศ  | ไม่ออกจากเครื่อง                 |
| ภาษาไทย            | รองรับจำกัด              | ปรับแต่งเฉพาะภาษาไทยปนศัพท์แพทย์ |
| ค่าใช้จ่ายรายเดือน | 39-119 ดอลลาร์           | ไม่มี (รันในเครื่องตัวเอง)       |
| ต้องมีอินเทอร์เน็ต | ต้องมี                   | ไม่ต้อง                          |

## 2. ⚠️ ขอบเขตและข้อจำกัด — อ่านก่อนใช้

ส่วนนี้สำคัญที่สุดในคู่มือทั้งเล่ม กรุณาอย่าข้าม

สิ่งที่ระบบนี้เป็น

เครื่องมือ **ช่วยจัดทำเอกสาร** (documentation aid) ที่แปลงสิ่งที่พูดกันในห้องตรวจให้เป็นร่างเวชระเบียนที่มีโครงสร้าง

สิ่งที่ระบบนี้ไม่ใช่

- ไม่ใช่เครื่องมือวินิจฉัยโรค ข้อความในหัวข้อ Assessment คือการสรุปสิ่งที่แพทย์พูดในห้องตรวจ ไม่ใช่ความเห็นทางการแพทย์ของระบบ
- ไม่ใช่ระบบแนะนำการรักษา ฉบับที่แจกจ่ายให้ผู้อื่นตัดฟังก็ขึ้นเสนอแนวทางการรักษาออกทั้งหมด
- ไม่ใช่เวชระเบียนฉบับสมบูรณ์ ทุกฉบับเป็นร่างที่ต้องผ่านการตรวจทาน

หน้าที่ของแพทย์ผู้ใช้

แพทย์ผู้รักษาเป็นผู้ตรวจทาน แก้ไข และรับผิดชอบเวชระเบียนฉบับจริงทุกฉบับ ระบบไม่มีวันแทนที่การตัดสินใจหรือความรับผิดชอบของแพทย์

ข้อจำกัดที่ต้องรู้

1. ระบบรู้เฉพาะสิ่งที่ถูกพูดออกมา ผลตรวจร่างกายที่ทำเงียบๆ โดยไม่พูด ระบบจะไม่มีทางรู้ และจะเขียนว่า "ไม่ได้ประเมิน"
2. การถอดเสียงผิดพลาดได้ โดยเฉพาะศัพท์เฉพาะ ชื่อยา และเมื่อมีเสียงรบกวน ข้อความที่ถอดผิดอาจทำให้ร่างคลาดเคลื่อนตามไปด้วย
3. ตัวเลขต้องตรวจซ้ำเสมอ อายุ ขนาดยา ค่าผลตรวจ เป็นจุดที่โมเดลภาษาพลาดได้และผลกระทบสูง
4. ไม่เหมาะกับเคสฉุกเฉิน ที่ต้องบันทึกทันที

## 3. ระบบทำงานอย่างไร

เสียงสนทนา → ถอดเสียง (Whisper) ในเครื่อง → โมเดลภาษา ในเครื่อง → ร่าง SOAP note → แพทย์ตรวจทาน แก้ไข/บันทึก

ส่วนประกอบ

| ส่วน          | เทคโนโลยี                            | หมายเหตุ                                           |
|---------------|--------------------------------------|----------------------------------------------------|
| ถอดเสียงไทย   | faster-whisper + โมเดลไทย Thonburian | รันบน CPU · ไม่ต้องมี GPU                          |
| แปลงเป็น SOAP | Qwen3 14B ที่ fine-tune เฉพาะงานนี้  | ใบอนุญาต Apache 2.0                                |
| หน้าจอใช้งาน  | เว็บในเครื่อง (localhost)            | เข้าจากเครื่องอื่นในบ้าน/คลินิกได้ผ่าน VPN ส่วนตัว |

**ข้อมูลที่ใช้ฝึกโมเดล** เป็นบทสนทนาสังเคราะห์ 540 เคส สร้างขึ้นใหม่ทั้งหมด **ไม่มีข้อมูลผู้ป่วยจริงแม้แต่รายเดียว**  
ครอบคลุมโรคทางระบบประสาทเป็นหลัก และอายุรกรรมทั่วไปบางส่วน

**หลักการสำคัญของโมเดล** ถูกฝึกให้ทำงานแบบ *extractive* คือ **ใส่เฉพาะสิ่งที่ปรากฏในบทสนทนา ห้ามแต่งเพิ่ม** สิ่ง  
ที่ไม่มีข้อมูลจะเขียนว่า "ไม่ได้ประเมิน" แทนการเดา

## 4. สเปกเครื่องที่ต้องใช้

### กรณีรันโมเดลในเครื่องเอง

|                     | ขั้นต่ำ           | แนะนำ            |
|---------------------|-------------------|------------------|
| แรม                 | 16 GB             | <b>24 GB</b>     |
| พื้นที่ว่าง         | 20 GB             | 30 GB            |
| ซีพียู              | 8 คอร์            | 8 คอร์ขึ้นไป     |
| เครื่องที่ทดสอบแล้ว | Mac Apple Silicon | Mac mini M4 24GB |

**ตัวชี้ความเร็วคือ memory bandwidth ไม่ใช่จำนวนแรม** — แรมมากขึ้นไม่ได้ทำให้เร็วขึ้น แต่ชิปที่เร็วกว่าทำให้เร็ว  
ขึ้นชัดเจน

| เครื่อง                             | เวลาต่อเคสโดยประมาณ     |
|-------------------------------------|-------------------------|
| Mac ชิปพื้นฐาน (M1–M4)              | ~3 นาที                 |
| Mac ชิประดับ Pro                    | ~1.5 นาที               |
| พีซีที่มีการ์ดจอ NVIDIA 12GB ขึ้นไป | ~30 วินาที              |
| พีซีไม่มีการ์ดจอ                    | 5–10 นาที (ใช้งานลำบาก) |

### กรณีเป็นเครื่องเปิดใช้อย่างเดียว

หากมีเครื่องแม่รันโมเดลอยู่แล้ว เครื่องอื่นในคลินิกใช้อะไรก็ได้ที่เปิดเบราว์เซอร์ได้ รวมถึงแท็บเล็ตและเครื่องเก่า

## 5. ขั้นตอนการใช้งานประจำวัน

### แนวทางที่แนะนำ — อย่างง่าย

ระบบใช้เวลาประมาณ 2-4 นาทีต่อเคส ซึ่งนานเกินกว่าจะนั่งรอในห้องตรวจ จึงออกแบบให้ทำงานแบบคิว

1. อัปเดตเสี่ยงสนทนา (หรือพูดสรุปเองหลังผู้ป่วยออกจากห้อง)
2. กดถอดเสียง (~40 วินาที)
3. ตรวจสอบข้อความคร่าวๆ แก่จุดที่ถอดผิดชัดเจน
4. กด "ส่งเข้าคิว" ← เรียกผู้ป่วยรายถัดไปได้ทันที
5. เมื่อว่าง เปิดคิวอ่านรวดเดียวหลายฉบับ ตรวจทาน แก้ บันทึก

หัวใจอยู่ที่ข้อ 4 เวลาที่เครื่องใช้เท่าเดิม แต่เวลาที่แพทย์เสียไปกลายเป็นศูนย์ เพราะร่างเวชระเบียนไม่จำเป็นต้องเสร็จขณะผู้ป่วยยังนั่งอยู่

### รูปแบบเวชระเบียนที่เลือกได้

- SOAP — S / O / A / P มาตรฐานสากล
- CC/PI/PH — แบบดั้งเดิมที่ใช้กันในโรงพยาบาลไทย (CC → PI → PH → PE → Ix → Dx → Plan)
- ทั้งสองแบบ — แสดงคู่กันเพื่อเลือกใช้

## 6. เคล็ดลับการพูดให้ได้ note ที่ดี

จากประสบการณ์ใช้งานจริง คุณภาพของ note ขึ้นกับวิธีพูดมากกว่าตัวโมเดล

### พูดสิ่งที่อยากให้อยู่ในเวชระเบียน

ระบบรู้เฉพาะสิ่งที่ได้ยิน ถ้าตรวจร่างกายแล้วไม่พูด เวชระเบียนจะไม่มีผลตรวจ

| แทนที่จะเงียบแล้วพิมพ์ทีหลัง | พูดออกมาสั้นๆ                                 |
|------------------------------|-----------------------------------------------|
| (ตรวจกำลังกล้ามเนื้อเจ็บบๆ)  | "กำลังกล้ามเนื้อห้เต็มห้ทั้งสี่ระยางค์นะครับ" |
| (ดูฟิล์มเจ็บบๆ)              | "เอ็มอาร์ไอเดิมมี lesion ที่ periventricular" |

### บอกเพศและอายุตอนเปิดเคส

"คนไข้หญิง อายุสี่สิบห้าปี มาด้วยอาการปวดศีรษะ..."

ถ้าไม่พูด ระบบจะเขียนว่า "ไม่ได้ระบุอายุ" ตามกติกา (ไม่เดาให้)

## ทวนสิ่งที่ผู้ป่วยเล่าเป็นภาษาแพทย์

เมื่อผู้ป่วยเล่ายาวและวากวน การที่แพทย์ทวนสรุปสั้นๆ จะช่วยทั้งการสื่อสารกับผู้ป่วยและช่วยให้ระบบจับประเด็นถูก

"สรุปคือปวดข้างเดียว ตูๆ มีคลื่นไส้ แพ้แสง เป็นมาสามเดือนนะครับ"

## พูดคำเตือนและการนัดหมายให้ชัด

"ถ้าปวดรุนแรงที่สุดในชีวิตแบบเฉียบพลัน หรือแขนขาอ่อนแรง ให้มาโรงพยาบาลทันที ไม่ต้องรอนัด"

ประโยคแบบนี้จะถูกบันทึกไว้ในเวชระเบียน ซึ่งมีคุณค่าทั้งทางคลินิกและทางกฎหมาย

## สิ่งที่ควรเลี่ยง

- พูดพร้อมกันหลายคน หรือพูดขณะมีเสียงดัง
- ใช้คำย่อเฉพาะตัวที่ไม่มีใครใช้
- คาดหวังให้ระบบเดาสิ่งที่ไม่ได้พูด

## 7. การบันทึกผลตรวจร่างกาย

ผลตรวจร่างกายเป็นส่วนที่ระบบไม่มีทางรู้เอง จึงมี 3 ทางเลือก

1. **พูดระหว่างตรวจ** — ง่ายที่สุด ผลจะไปอยู่ในหัวข้อ Objective เอง
2. **พูดแยกหลังตรวจเสร็จ** — อัดสั้นๆ 10–20 วินาทีหลังผู้ป่วยออกจากห้อง

"motor grade ห้าทั้งสี่ระยะ CN สองถึงสิบสองปกติ DTR สองบวกเท่ากัน Babinski ลบทั้งสองข้าง เดินปกติ"

3. **กรอกเป็นช่องๆ** — สำหรับค่าที่ต้องแม่นยำ มีฟอร์มให้เลือกครบตั้งแต่สัญญาณชีพ เส้นประสาทสมอง กำลังกล้ามเนื้อ รีเฟล็กซ์ การรับความรู้สึก ซีรีเบลลาร์ การเดิน ไปจนถึงอาการแสดงเฉพาะของ FND

**หลักการสำคัญ** ทุกช่องในฟอร์มตั้งต้นเป็น **"ไม่ได้ตรวจ"** ไม่ใช่ "ปกติ" เพื่อไม่ให้ระบบบันทึกว่าตรวจแล้วปกติทั้งที่ไม่ได้ตรวจ ซึ่งเป็นเรื่องสำคัญทั้งทางคลินิกและทางกฎหมาย

**ข้อดีของการใส่ผลตรวจก่อนสร้าง note** คือส่วน Assessment และ Plan จะได้ใช้ผลตรวจในการเรียบเรียงด้วย ไม่ใช่แค่ผลตรวจไปนั่งอยู่ในช่อง Objective เฉยๆ

## 8. ความเป็นส่วนตัวและ PDPA

### สถาปัตยกรรมด้านความเป็นส่วนตัว

- ประมวลผลทั้งหมดในเครื่อง ไม่มีการเรียก API ภายนอกใดๆ
- ถอดเสียงเสร็จ ไฟล์เสียงถูกลบทันที ไม่เก็บค้าง
- เวชระเบียนเก็บเป็นไฟล์ในเครื่องเท่านั้น
- หน้าเว็บผูกกับ localhost ไม่เปิดออกอินเทอร์เน็ต

### สิ่งที่ผู้ใช้ต้องจัดการเอง

- ความยินยอมของผู้ป่วย** การบันทึกเสียงสนทนาต้องแจ้งและได้รับความยินยอม ควรมีป้ายในห้องตรวจหรือแจ้งด้วยวาจาและบันทึกไว้ ทางเลือกที่ตัดปัญหานี้ได้ทั้งหมด คือไม่อัดผู้ป่วยเลย แต่ให้แพทย์พูดสรุปเองหลังผู้ป่วยออกจากห้อง
- เข้ารหัสดีสก์** เปิด FileVault หรือ BitLocker เสมอ เพราะเวชระเบียนอยู่ในเครื่อง
- การเข้าถึงเครื่อง** ตั้งรหัสผ่าน ล็อกหน้าจออัตโนมัติ
- แผนสำรองข้อมูลและการทำลายข้อมูล** ตามระเบียบของสถานพยาบาล

### มุมมองที่ควรอธิบายกับฝ่ายบริหาร

โมเดลถูกฝึกด้วยข้อมูลสังเคราะห์ทั้งหมด ตรวจสอบย้อนกลับได้ และเมื่อรันในเครื่อง **ไม่มีผู้ประมวลผลข้อมูลภายนอก** ไม่มีการส่งข้อมูลข้ามพรมแดน ซึ่งเป็นภาระตาม PDPA ที่น้อยที่สุดเท่าที่จะเป็นไปได้

## 9. ตัวเลขจากการใช้งานจริง

### ความเร็ว (Mac mini M4 แรม 24GB)

| ขั้นตอน         | เวลาดำเนินการ |
|-----------------|---------------|
| ถอดเสียง        | 39 วินาที     |
| สร้าง SOAP note | 136 วินาที    |

### คุณภาพ (ทดสอบกับชุดข้อมูลที่โมเดลไม่เคยเห็น)

ทดสอบเปรียบเทียบกับ **DeepSeek-R1 ขนาด 70B** ซึ่งเป็นโมเดลทั่วไปที่ใหญ่กว่า 5 เท่า บนเคสชุดเดียวกัน

| ตัวชี้วัด           | โมเดลทั่วไป 70B | โมเดลเฉพาะทาง 14B |
|---------------------|-----------------|-------------------|
| โครงสร้างครบถ้วน    | 100%            | 100%              |
| จับประเด็นการส่งต่อ | 58.3%           | 83.3%             |
| จับคำเตือนผู้ป่วย   | 40.0%           | 66.7%             |

**ข้อสรุปที่สำคัญ** โมเดลขนาดเล็กที่ฝึกเฉพาะงาน ทำงานเวอร์ชันไทยได้ดีกว่าโมเดลทั่วไปที่ใหญ่กว่ามาก และเพราะเล็ก จึงรันในเครื่องได้จริง

ข้อจำกัดของตัวเลขนี้ วัดด้วยเกณฑ์อัตโนมัติจากคำสำคัญ ไม่ใช้การประเมินทางคลินิกเต็มรูปแบบ และจำนวนเคสทดสอบจำกัด

## 10. บทเรียนสำหรับผู้ที่จะสร้างเอง

สำหรับทีมโรงพยาบาลที่คิดจะพัฒนาระบบลักษณะเดียวกัน นี่คือนโยบายที่แลกมาด้วยเวลาจริง

### 10.1 ข้อมูลสำคัญกว่าขนาดโมเดล

เคยฝึกโมเดลรุ่นที่สาม โดยแก้รูปแบบข้อมูลให้ดีขึ้น ผลคือ ค่า validation loss ดีขึ้นจริง แต่คุณภาพงานจริงเท่าเดิม เพราะปัญหารูปแบบถูกแก้ไปแล้วด้วยการปรับ prompt ตั้งแต่ก่อนหน้า

**บทเรียน** ตัวเลข loss ที่ดีขึ้นไม่ได้แปลว่างานจริงดีขึ้น ต้องวัดที่ผลลัพธ์เสมอ

### 10.2 กับดักของ initial\_prompt ใน Whisper

เคยขยายรายการคำศัพท์ที่ป้อนให้ Whisper จาก 12 คำเป็น 47 คำ (ยังไม่เกินเพดาน token) ผลคือ **ข้อความที่ถอดได้สั้นลง 54%**

สาเหตุคือ initial\_prompt ไม่ใช่พจนานุกรม แต่เป็น**ข้อความนำที่โมเดลใช้เป็นแบบอย่างในการเขียนต่อ** เมื่อป้อนรายการคำค้นจุลภาคยาวๆ โมเดลจึงเลียนแบบสไตล์นั้นแล้วตอบสั้นและจบเร็ว

**บทเรียน** ให้ initial\_prompt สั้นที่สุด ศัพท์เฉพาะควรแก้ด้วยตารางแทนที่คำหลังถอดเสียง ซึ่งไม่มีเพดานและแม่นยำกว่า

### 10.3 ตรวจสอบว่าข้อมูลฝึกถูกตัดหรือไม่

เมื่อความยาวเกิน max-seq-length ข้อมูลจะถูกตัดท้ายเงิบๆ และส่วนที่หายมักเป็น **แผนการรักษาและคำเตือน** ซึ่งอยู่ท้ายเวอร์ชัน = สอนโมเดลไม่ให้ส่งต่อและไม่ให้เตือน ในเคสที่ยากที่สุด

**บทเรียน** ตรวจสอบอัตราการถูกตัดก่อนฝึกทุกครั้ง และดูด้วยว่าสิ่งที่ถูกตัดคืออะไร

### 10.4 ระวังตัวชี้วัดที่วัดส่านวนแทนคุณภาพ

เกณฑ์อัตโนมัติที่จับคำว่า "แพทย์" ทำให้โมเดลที่เขียนว่า "ส่งพบ**หมอ**ระบบประสาท" ถูกนับว่าผิด ทั้งที่ทำถูก และเมื่อขยายเกณฑ์ให้ครอบคลุมส่านวนพูด ตัวเลข red-flag recall กระโดดจาก 54% เป็น 96%

**บทเรียน** ตัวเลขที่ดูแย่อาจเป็นความผิดของเครื่องมือวัด ไม่ใช่ของโมเดล

### 10.5 ความเร็วติดเพดานฮาร์ดแวร์ อย่าเสียเวลากับซอฟต์แวร์

ทดลองเปลี่ยน runtime และทำ speculative decoding แล้ว **ไม่มีอะไรเร็วขึ้นเลย** (บางอย่างช้าลง 40%) เพราะคอขวดคือ memory bandwidth

**บทเรียน** ถ้าคอขวดคือ bandwidth การเพิ่มโมเดลช่วยเดา (draft model) จะยิ่งแย่งเพราะแย่ง bandwidth กันเอง

### 10.6 ทดสอบกับข้อมูลจริงก่อนใช้กับผู้ป่วยเสมอ

ปัญหาข้อ 10.2 ผ่านการทดสอบทางเทคนิคทุกอย่าง แต่ถูกจับได้จากการใช้งานจริงเท่านั้น

**บทเรียน** unit test ไม่พอ ระบบที่ใช้กับผู้ป่วยต้องทดสอบกับเสียงจริงและเคสจริงก่อนปล่อยใช้

## 11. ปัญหาที่พบบ่อยและวิธีแก้

| อาการ                          | สาเหตุที่พบบ่อย                        | วิธีแก้                                     |
|--------------------------------|----------------------------------------|---------------------------------------------|
| ข้อความที่ถอดได้สั้นผิดปกติ    | เสียงเบา ไมค์ไกล หรือ prompt ยาวเกิน   | ใช้ไมค์ตั้งโต๊ะ ตรวจสอบรายการคำศัพท์ให้สั้น |
| ศัพท์อังกฤษกลายเป็นคำไทย       | โมเดลถอดเสียงถูกฝึกด้วยภาษาไทยเป็นหลัก | เพิ่มคำในตารางแก้คำหลังถอดเสียง             |
| หัวข้อ Objective ว้างเปล่า     | ไม่ได้พูดผลตรวจออกมา                   | พูดผลตรวจ หรือใช้ฟอร์ม/อัดแยก               |
| ระบบเขียน "ไม่ได้ประเมิน" เยอะ | บทสนทนาไม่มีข้อมูลนั้นจริง             | ปกติ ไม่ใช่ข้อผิดพลาด ระบบไม่เดาให้         |
| ช่างใช้ในห้องตรวจไม่ได้        | ใช้งานแบบนั่งรอ                        | ใช้ระบบคิว ส่งแล้วไปตรวจรายถัดไป            |
| ตัวเลขในเวชระเบียนผิด          | ข้อจำกัดของโมเดลภาษา                   | <b>ตรวจตัวเลขทุกครั้ง</b> โดยเฉพาะขนาดยา    |

## ติดต่อและขอรับตัวโปรแกรม

โปรแกรมนี้อยู่ในระยะทดลองใช้ ยังไม่เปิดดาวน์โหลดสาธารณะ แพทย์หรือหน่วยงานที่สนใจนำไปทดลองใช้ กรุณากรอกแบบฟอร์มขอรับตัวโปรแกรมที่หน้าเว็บ

### เงื่อนไขการขอรับ

- สำหรับแพทย์หรือบุคลากรทางการแพทย์ และหน่วยงานสถานพยาบาล
  - ฉบับที่แจกจ่ายตัดฟังก์ชันเสนอแนวทางการรักษาออก เหลือเฉพาะการช่วยจัดทำเอกสาร
  - ผู้ใช้รับทราบว่าเป็นเครื่องมือช่วยร่าง และแพทย์ผู้รักษารับผิดชอบเวชระเบียนฉบับจริง
  - ยินดีรับฟังข้อเสนอแนะกลับเพื่อพัฒนาต่อ
- 

เอกสารนี้เผยแพร่เพื่อประโยชน์ทางวิชาการ ผู้เขียนไม่มีส่วนได้ส่วนเสียเชิงพาณิชย์กับซอฟต์แวร์หรือฮาร์ดแวร์ใดที่กล่าวถึง

นพ. สหรัฐ อังศุมาศ · **ประสาทแพทย์** สหวรรณคลินิก · [www.sahawanclinic.clinic](http://www.sahawanclinic.clinic)